TUGAS PERTEMUAN 6

MACHINE LEARNING OPERATIONS

MODEL EXPERIMENTATION & TRACKING IN MLOPS PADA FASHION-MNIST

Disusun oleh :

May Talitha Dahlia

NIM : 123450009

Kelas : RA

PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA

2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pengembangan model *machine learning* tidak hanya mencakup proses pembangunan dan pelatihan model, tetapi juga melibatkan pengelolaan eksperimen secara sistematis. Dalam proses tersebut, berbagai konfigurasi model dapat menghasilkan performa yang berbeda. Oleh karena itu, pencatatan parameter, pemantauan metrik evaluasi, penyimpanan artefak model, serta perbandingan hasil eksperimen diperlukan agar proses pengembangan model dapat ditelusuri dan dievaluasi secara lebih terstruktur.

Salah satu tantangan dalam eksperimen *machine learning* adalah menjaga konsistensi dan keterlacakan hasil ketika dilakukan perubahan pada konfigurasi model, data, maupun proses pelatihan. Tanpa mekanisme pencatatan yang memadai, perbandingan hasil eksperimen dan penggunaan kembali model yang telah dilatih dapat menjadi lebih sulit. Pendekatan *Machine Learning Operations* (MLOps) dapat membantu mengelola tahapan eksperimen tersebut melalui integrasi pencatatan eksperimen, versioning data, evaluasi model, dan pengelolaan model.

Pada tugas ini, penerapan *Model Experimentation & Tracking in MLOps* dilakukan menggunakan dataset Fashion-MNIST dan model *Convolutional Neural Network* (CNN) untuk klasifikasi citra. MLflow digunakan untuk mencatat parameter, metrik, dan artefak model, sedangkan Optuna digunakan untuk melakukan optimasi *hyperparameter*. DVC diterapkan untuk mendukung versioning dataset, sementara Git digunakan untuk melacak perubahan kode dan berkas proyek.

Eksperimen dilanjutkan dengan evaluasi konfigurasi terbaik menggunakan tiga *random seed*, pelaksanaan *ablation study* untuk mengamati pengaruh komponen tertentu terhadap performa model, serta registrasi model melalui MLflow Model Registry. Model yang dipilih kemudian diberi alias champion dan dipanggil kembali untuk pengujian prediksi. Melalui rangkaian kegiatan tersebut, diharapkan dapat diperoleh pemahaman mengenai penerapan pencatatan eksperimen, perbandingan performa model, dan pengelolaan model dalam alur kerja MLOps.

1.2 Tujuan

Tujuan pelaksanaan tugas ini adalah:

1. Menerapkan pencatatan dan pelacakan eksperimen model CNN menggunakan MLflow.
2. Menerapkan versioning dataset menggunakan DVC dan mencatat hash dataset pada eksperimen.
3. Melakukan optimasi hyperparameter menggunakan Optuna dengan minimal 20 trial.
4. Mengevaluasi konfigurasi terbaik menggunakan tiga *random seed* untuk mengetahui variasi performa model.
5. Melaksanakan *ablation study* untuk membandingkan performa model pada beberapa konfigurasi komponen.
6. Mendaftarkan model terbaik pada Model Registry, menetapkan alias `champion`, dan menguji pemanggilan model melalui alias tersebut.

7. Mendokumentasikan hasil eksperimen melalui MLflow UI, repositori Git, dan laporan hasil praktikum.

1.3 Hipotesis

Hipotesis dalam eksperimen ini adalah:

1. Perbedaan konfigurasi hyperparameter akan menghasilkan perbedaan performa model CNN pada dataset Fashion-MNIST.
2. Evaluasi menggunakan tiga *random seed* akan menunjukkan adanya variasi performa model, yang dapat dianalisis melalui rata-rata dan standar deviasi akurasi validasi.
3. Penghilangan komponen *augmentation* atau *dropout* akan memengaruhi performa model, yang dapat diamati melalui perbandingan akurasi validasi dan *validation loss* pada *ablation study*.
4. Penggunaan MLflow dan DVC dapat mendukung keterlacakan eksperimen melalui pencatatan parameter, metrik, artefak model, dan identitas dataset.
5. Registrasi model dan penggunaan alias `champion` memungkinkan model yang dipilih dikelola serta dipanggil kembali untuk proses prediksi.

BAB II

METODOLOGI EKSPERIMEN

2.1 Dataset Fashion-MNIST

Dataset yang digunakan dalam eksperimen ini adalah Fashion-MNIST, yaitu dataset citra pakaian yang terdiri atas 60.000 citra untuk data pelatihan dan 10.000 citra untuk data pengujian. Setiap citra berukuran 28 × 28 piksel dalam skala grayscale dan dikelompokkan ke dalam 10 kelas pakaian atau aksesori.

Dataset digunakan untuk melatih dan mengevaluasi model *Convolutional Neural Network* (CNN) dalam tugas klasifikasi citra. Hash SHA-256 dataset dicatat sebagai metadata eksperimen untuk membantu mengidentifikasi versi dataset yang digunakan.

2.2 Persiapan Lingkungan dan Versioning Dataset

Eksperimen dijalankan menggunakan Python dan PyTorch sebagai kerangka kerja pengembangan model CNN. MLflow digunakan sebagai sarana pencatatan eksperimen dengan backend berbasis SQLite dan penyimpanan artefak lokal. Antarmuka MLflow diakses melalui alamat lokal `http://127.0.0.1:5000`.

DVC digunakan untuk mendukung versioning dataset, sedangkan Git digunakan untuk melacak perubahan kode dan berkas proyek. Dataset dikelola menggunakan berkas metadata DVC sehingga versi dataset dapat diidentifikasi dan dihubungkan dengan proses eksperimen. Hash SHA-256 dataset juga dicatat pada tag eksperimen MLflow.

2.3 Pelatihan Model Baseline CNN

Tahap awal eksperimen dilakukan dengan melatih model baseline CNN menggunakan dataset Fashion-MNIST. Model baseline digunakan sebagai titik awal untuk mengetahui performa model sebelum dilakukan optimasi hyperparameter.

MLflow digunakan untuk mencatat parameter pelatihan, metrik pada setiap epoch, dan artefak model. Metrik yang dicatat meliputi *training loss*, *training accuracy*, *validation loss*, dan *validation accuracy*. Pencatatan tersebut memungkinkan hasil pelatihan ditelusuri melalui antarmuka MLflow.

2.4 Hyperparameter Tuning Menggunakan Optuna

Optimasi hyperparameter dilakukan menggunakan Optuna dengan 20 trial. Parameter yang dieksplorasi meliputi *learning rate*, *batch size*, *dropout*, dan jumlah channel pada CNN. Setiap trial dijalankan sebagai *nested run* di dalam eksperimen induk MLflow agar konfigurasi dan hasil setiap percobaan dapat dibandingkan.

Pemilihan konfigurasi terbaik didasarkan pada nilai akurasi validasi. Hasil tuning kemudian diperiksa melalui MLflow Compare View untuk membandingkan hubungan antara konfigurasi hyperparameter dan performa model.

2.5 Evaluasi Menggunakan Tiga Random Seed

Konfigurasi hyperparameter terbaik dari proses tuning selanjutnya dievaluasi menggunakan tiga random seed, yaitu 42, 123, dan 2026. Evaluasi ini dilakukan untuk mengetahui variasi performa model ketika proses pelatihan menggunakan seed yang berbeda.

Performa diringkas menggunakan rata-rata dan standar deviasi sampel akurasi validasi dari ketiga pelatihan. Nilai tersebut digunakan untuk menggambarkan performa rata-rata dan variasi hasil eksperimen.

2.6 Ablation Study

Ablation study dilakukan untuk mengamati perubahan performa ketika komponen tertentu diubah atau dihilangkan. Tiga konfigurasi yang dibandingkan adalah *full model*, model tanpa augmentation, dan model tanpa dropout.

Setiap konfigurasi dievaluasi menggunakan akurasi validasi dan dicatat pada MLflow. Hasil perbandingan digunakan untuk melihat konfigurasi yang memperoleh akurasi validasi tertinggi di antara variasi yang diuji.

2.7 Registrasi dan Pengujian Model

Model hasil eksperimen didaftarkan pada MLflow Model Registry dengan nama fashion-mnist-cnn. Versi model yang didaftarkan kemudian diberi alias champion sebagai penanda model yang dipilih untuk digunakan.

Pengujian dilakukan dengan memuat model melalui alias tersebut dan menjalankan prediksi. Selain itu, akurasi pada data pengujian dicatat untuk memberikan gambaran performa model pada data yang tidak digunakan sebagai data pelatihan.

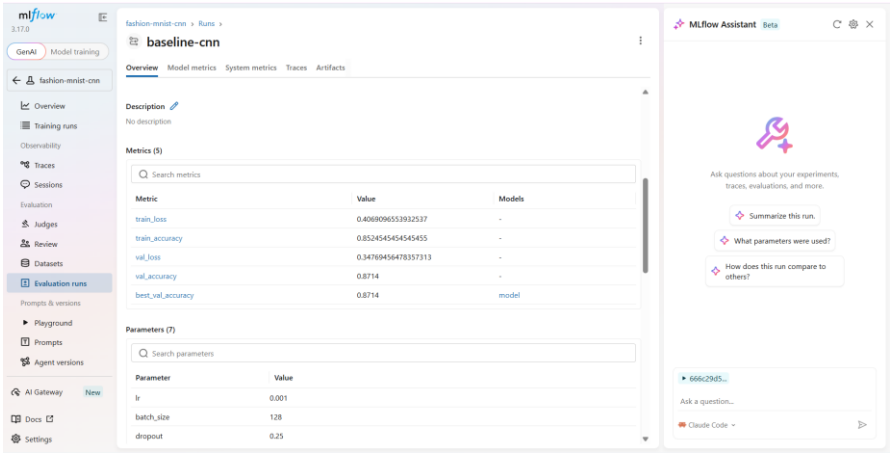
BAB III

HASIL DAN PEMBAHASAN

3.1 Hasil Pelatihan Baseline CNN

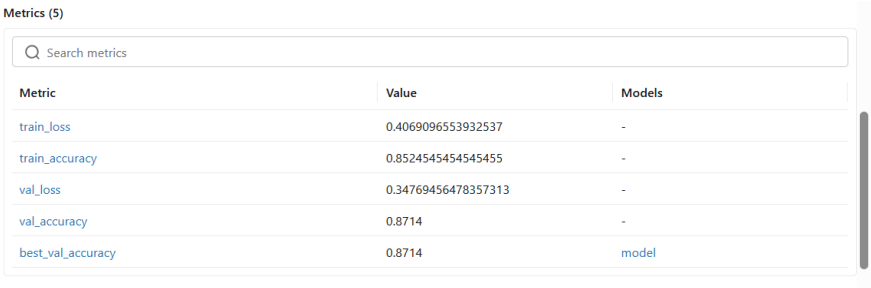
Pelatihan baseline CNN dilakukan sebagai tahap awal untuk memperoleh gambaran performa model sebelum optimasi hyperparameter. Proses pelatihan dicatat menggunakan MLflow, meliputi parameter, metrik pelatihan dan validasi, serta artefak model.

Pencatatan eksperimen berhasil dilakukan dan dapat dilihat melalui halaman *Training runs* pada MLflow. Terdapat satu run baseline yang berhasil diselesaikan dan satu run sebelumnya yang gagal akibat masalah serialisasi model. Setelah perbaikan konfigurasi penyimpanan model, pelatihan baseline berhasil dijalankan.



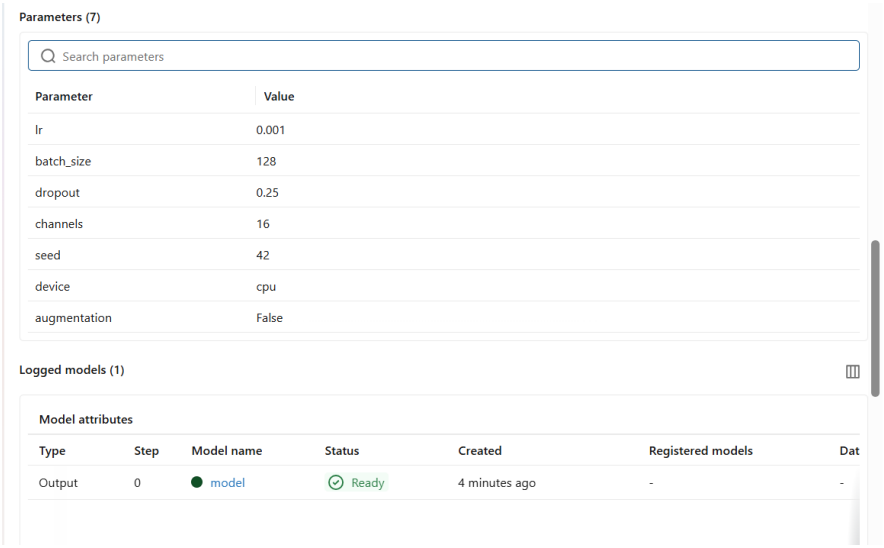
Gambar 3.1 Informasi eksperimen baseline

Berdasarkan Gambar 3.1, eksperimen baseline CNN berhasil dicatat pada MLflow dengan status *Finished*. Pencatatan tersebut mencakup informasi eksperimen, metrik evaluasi, parameter model, dan artefak model. Dengan demikian, MLflow dapat digunakan untuk mendokumentasikan proses pelatihan dan memudahkan penelusuran kembali konfigurasi eksperimen.



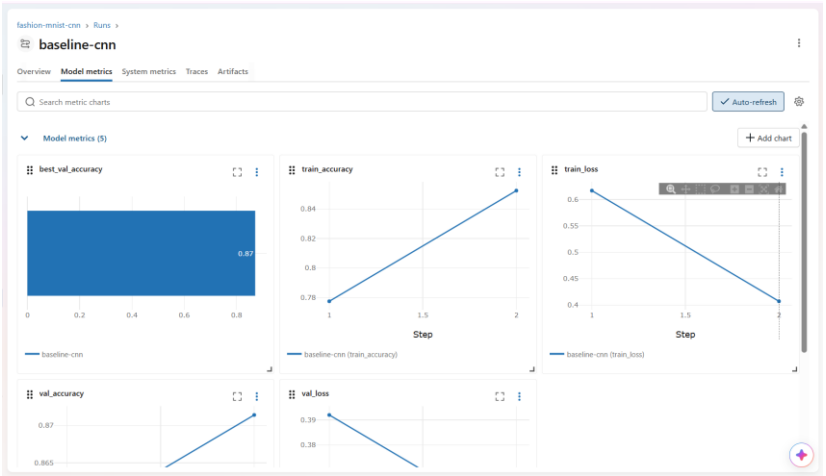
Gambar 3.2 Metrik baseline CNN

Berdasarkan Gambar 3.2, model baseline CNN memperoleh nilai *train loss* sebesar 0,4069 dan *train accuracy* sebesar 0,8525 atau 85,25%. Sementara itu, nilai *validation loss* sebesar 0,3477 dan *validation accuracy* sebesar 0,8714 atau 87,14%. Hasil tersebut menunjukkan bahwa model mampu mencapai akurasi validasi sebesar 87,14% setelah pelatihan selama dua epoch. Nilai akurasi validasi yang lebih tinggi dibandingkan akurasi pelatihan tidak serta-merta menunjukkan adanya masalah pada model. Perbedaan tersebut dapat dipengaruhi oleh karakteristik data maupun proses pelatihan. Oleh karena itu, diperlukan evaluasi lebih lanjut untuk menilai kemampuan generalisasi model.



Gambar 3.3 parameter baseline CNN

Berdasarkan Gambar 3.3, konfigurasi baseline CNN menggunakan *learning rate* sebesar 0,001, *batch size* sebesar 128, *dropout* sebesar 0,25, dan jumlah kanal awal (*channels*) sebesar 16. Pelatihan dilakukan menggunakan CPU dengan nilai *seed* sebesar 42 dan tanpa augmentasi data. Konfigurasi ini digunakan sebagai titik awal sebelum dilakukan optimasi hiperparameter menggunakan Optuna.





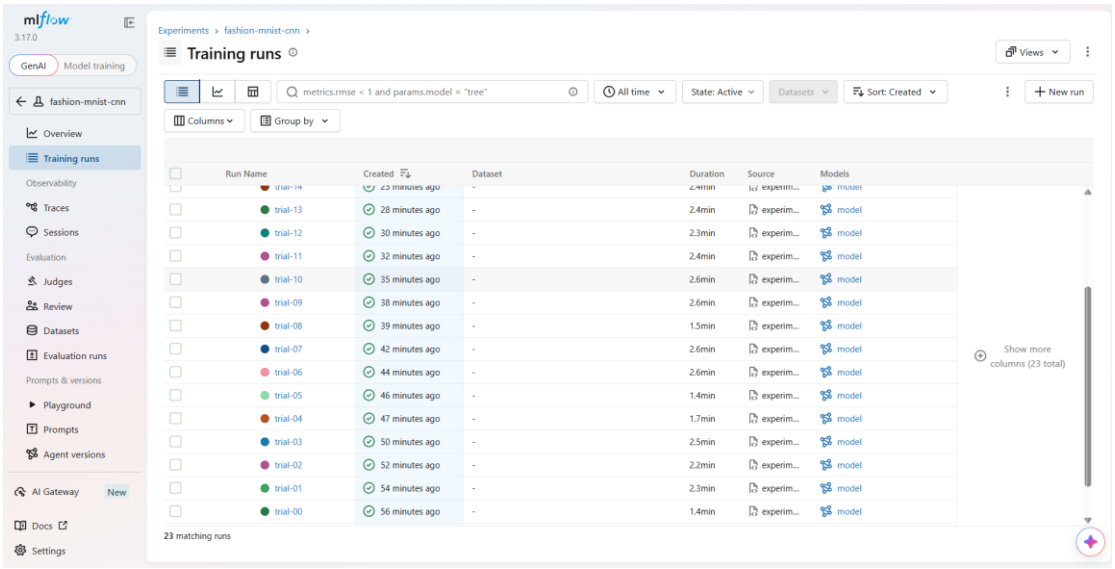
Gambar 3.4 Grafik metrik pelatihan baseline CNN

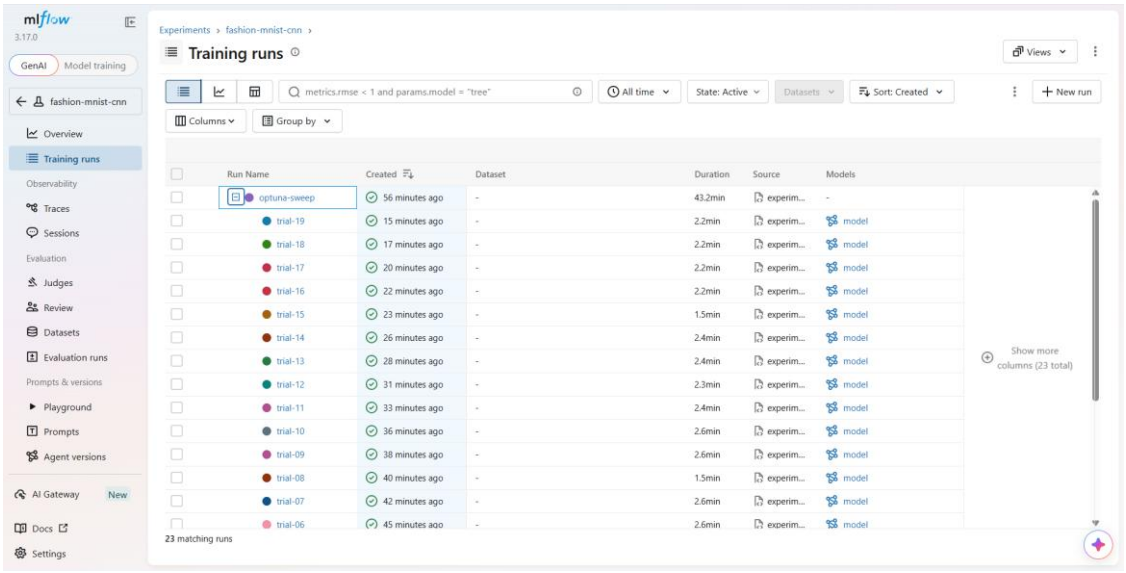
Gambar 3.4 menunjukkan grafik metrik pelatihan selama dua epoch. Grafik memperlihatkan bahwa *train accuracy* dan *validation accuracy* meningkat, sedangkan *train loss* dan *validation loss* menurun. Pola tersebut menunjukkan bahwa performa model membaik selama proses pelatihan pada dua epoch yang diamati.

3.2 Hasil Hyperparameter Tuning

Hyperparameter tuning dilakukan untuk memperoleh konfigurasi hiperparameter CNN yang memberikan performa klasifikasi lebih baik dibandingkan konfigurasi baseline. Pada penelitian ini, optimasi dilakukan menggunakan Optuna dengan menjalankan sebanyak 20 *trial*. Setiap *trial* menguji kombinasi hiperparameter yang berbeda, meliputi *learning rate*, *batch size*, *dropout*, dan jumlah kanal awal (*channels*).

Proses optimasi dicatat menggunakan MLflow dengan pendekatan *nested runs*. Setiap percobaan disimpan sebagai *run* tersendiri di bawah eksperimen utama, sehingga parameter dan metrik dari setiap percobaan dapat ditelusuri serta dibandingkan. Metrik yang digunakan sebagai dasar pemilihan konfigurasi terbaik adalah akurasi validasi (*validation accuracy*).





Gambar 3.5 Daftar 20 run hasil hyperparameter tuning menggunakan Optuna pada MLflow.

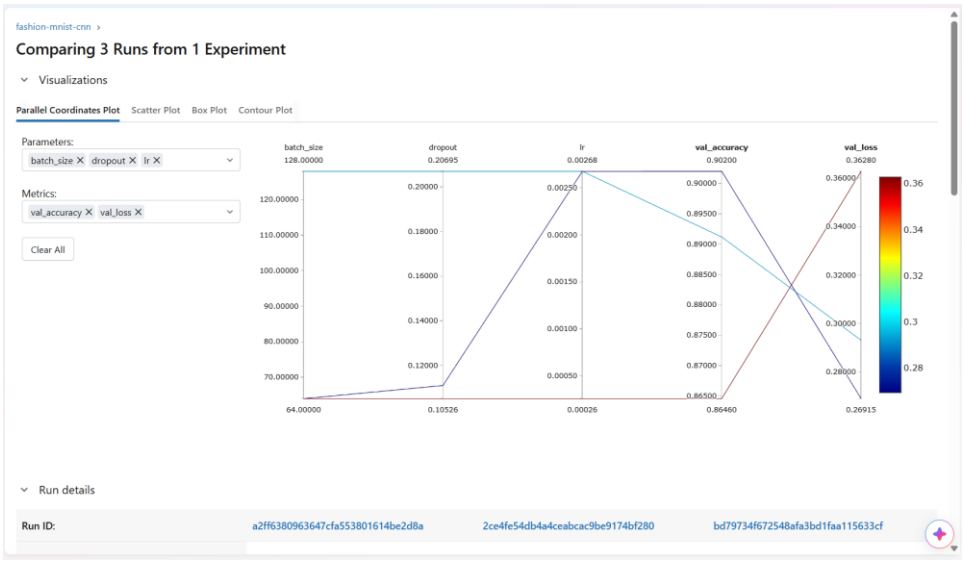
Berdasarkan Gambar 3.5, hasil proses hyperparameter tuning dicatat pada MLflow melalui run induk optuna-sweep dan sejumlah run percobaan (*trial*). Pencatatan ini memungkinkan konfigurasi dan hasil setiap percobaan ditelusuri serta dibandingkan untuk mendukung pemilihan konfigurasi dengan performa validasi terbaik.

Berdasarkan hasil eksperimen, konfigurasi terbaik diperoleh pada trial-12 dengan akurasi validasi sebesar 0,902 atau 90,20%. Konfigurasi tersebut memiliki *learning rate* sebesar 0,0026758, *batch size* 64, *dropout* sekitar 0,1111, dan jumlah channel 32.

Tabel 3.1 Konfigurasi Hyperparameter Terbaik

Parameter		**Konfigurasi terbaik**
Trial terbaik	:	trial-12
Learning rate	:	0,0026758
Batch size	:	64
Dropout	:	0,11115
Channels	:	32
Akurasi validasi	:	90,20%

Hasil tuning menunjukkan bahwa setiap kombinasi hiperparameter menghasilkan performa validasi yang berbeda. Trial-12 memperoleh akurasi validasi tertinggi sebesar 90,20%, dibandingkan trial-18 sebesar 86,50% dan trial-19 sebesar 89,10%. Jika dibandingkan dengan model baseline CNN yang memperoleh akurasi validasi sebesar 87,14%, konfigurasi terbaik hasil tuning menunjukkan peningkatan sebesar 3,06 poin persentase. Hasil ini menunjukkan bahwa optimasi hiperparameter membantu memperoleh konfigurasi CNN dengan performa validasi yang lebih baik pada eksperimen ini.



Gambar 3.6 MLflow Compare View untuk membandingkan konfigurasi dan metrik trial.

Berdasarkan Gambar 3.6, MLflow Compare View menunjukkan adanya perbedaan performa pada tiga konfigurasi hiperparameter yang dibandingkan, yaitu trial-12, trial-18, dan trial-19. Perbedaan tersebut terlihat dari nilai akurasi validasi (*validation accuracy*) dan *validation loss* yang dihasilkan oleh masing-masing percobaan. Trial-12 memperoleh akurasi validasi tertinggi sebesar 0,902 atau 90,20%, dengan *validation loss* sebesar 0,26915. Sementara itu, trial-18 memperoleh akurasi validasi sebesar 0,865 atau 86,50% dengan *validation loss* sebesar 0,36280, sedangkan trial-19 memperoleh akurasi validasi sebesar 0,891 atau 89,10% dengan *validation loss* sekitar 0,297. Hasil tersebut menunjukkan bahwa trial-12 memiliki performa validasi terbaik di antara ketiga konfigurasi yang dibandingkan. Konfigurasi trial-12 menggunakan *learning rate* sebesar 0,002676, *batch size* 64, *dropout* sekitar 0,11115, dan jumlah kanal awal (*channels*) sebanyak 32. Jika dibandingkan dengan model baseline CNN yang memperoleh akurasi validasi sebesar 87,14%, trial-12 menunjukkan peningkatan sebesar 3,06 poin persentase. Dengan demikian, trial-12 dipilih sebagai konfigurasi terbaik berdasarkan hasil tuning dan digunakan pada tahap evaluasi selanjutnya menggunakan tiga nilai *seed* untuk mengetahui konsistensi performa model.

3.3 Hasil Evaluasi Tiga Random Seed

Konfigurasi hyperparameter terbaik yang diperoleh dari proses tuning selanjutnya dievaluasi menggunakan tiga random seed, yaitu 42, 123, dan 2026. Evaluasi ini bertujuan untuk mengamati variasi akurasi validasi ketika proses pelatihan dilakukan menggunakan seed yang berbeda dengan konfigurasi hyperparameter yang sama. Penggunaan beberapa random seed dilakukan untuk mengetahui konsistensi performa model terhadap variasi yang muncul selama proses pelatihan.

Berdasarkan hasil eksperimen, akurasi validasi yang diperoleh untuk seed 42, 123, dan 2026 secara berturut-turut adalah 0,9106, 0,9200, dan 0,9196. Rata-rata akurasi validasi mencapai 0,9167 atau sekitar 91,67%, dengan standar deviasi sampel sebesar 0,0053 atau sekitar 0,53 poin persentase.

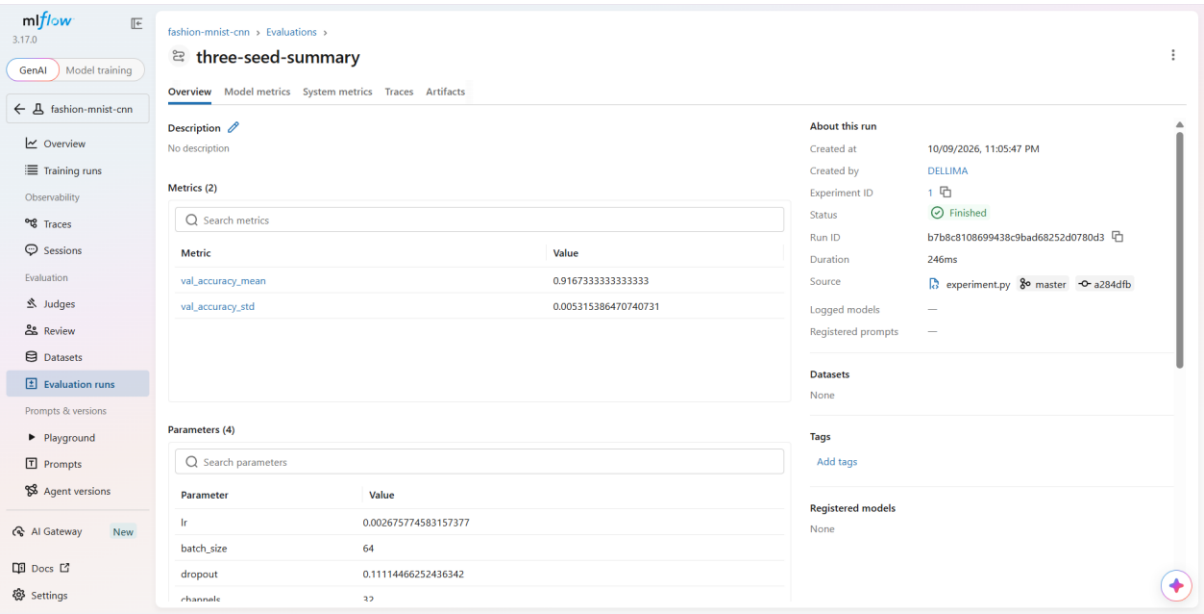
Rincian hasil akurasi validasi pada setiap random seed, beserta nilai rata-rata dan standar deviasi sampel, disajikan pada Tabel 3.2.

Tabel 3.2. Hasil Evaluasi Model Berdasarkan Tiga Random Seed

Random seed		**Akurasi validasi**
42	:	91,06%
123	:	92,00%
2026	:	91,96%
Rata-rata	**:**	**91,67%**
Standar deviasi sampel	**:**	**0,53 poin persentase**

Berdasarkan Tabel 3.2, akurasi validasi tertinggi diperoleh pada seed 123 sebesar 92,00%, sedangkan akurasi terendah diperoleh pada seed 42 sebesar 91,06%. Rentang akurasi validasi dari ketiga pelatihan tersebut adalah 0,94 poin persentase. Sementara itu, rata-rata akurasi validasi sebesar 91,67% dengan standar deviasi sampel sebesar 0,53 poin persentase menunjukkan bahwa variasi akurasi pada ketiga pelatihan yang diamati relatif rendah. Hasil ini menunjukkan bahwa konfigurasi hyperparameter terbaik menghasilkan performa validasi yang relatif konsisten pada ketiga random seed yang diuji.

Selain menghitung ringkasan statistik, hasil evaluasi juga dicatat menggunakan MLflow untuk mendukung dokumentasi dan keterlacakan eksperimen. Ringkasan hasil evaluasi tiga random seed pada MLflow ditunjukkan pada Gambar 3.7.



Gambar 3.7 Ringkasan Evaluasi Tiga Random Seed pada MLflow.

Berdasarkan Gambar 3.7, MLflow mencatat nilai rata-rata akurasi validasi (*val_accuracy_mean*) sebesar 0,9167 dan standar deviasi akurasi validasi (*val_accuracy_std*) sebesar 0,0053. Nilai tersebut sesuai dengan hasil perhitungan dari ketiga random seed yang telah dilakukan. Pencatatan ini memungkinkan hasil evaluasi dirangkum dan ditelusuri kembali melalui MLflow. Secara keseluruhan, hasil pengujian menunjukkan bahwa konfigurasi

hyperparameter terbaik memiliki performa validasi yang relatif konsisten pada tiga random seed yang digunakan. Konfigurasi tersebut selanjutnya digunakan sebagai dasar untuk mengevaluasi pengaruh komponen model melalui eksperimen *ablation study*.

3.4 Hasil Ablation Study

Ablation study dilakukan untuk mengetahui pengaruh komponen tertentu terhadap performa model CNN. Pada eksperimen ini, dilakukan tiga pengujian, yaitu model lengkap (*full model*), model tanpa *augmentation*, dan model tanpa *dropout*. Perbandingan dilakukan berdasarkan akurasi dan *loss* validasi yang dicatat menggunakan MLflow. Ketiga konfigurasi menggunakan dataset Fashion-MNIST dengan nilai *random seed* 42.

Hasil pengujian terhadap ketiga konfigurasi menunjukkan adanya perbedaan performa validasi. Konfigurasi *full model* memperoleh akurasi validasi sebesar 90,90%, konfigurasi tanpa *augmentation* memperoleh akurasi validasi sebesar 90,90%, sedangkan konfigurasi tanpa *dropout* memperoleh akurasi validasi sebesar 91,20%. Rincian hasil pengujian berdasarkan akurasi dan *validation loss* disajikan pada Tabel 3.3.

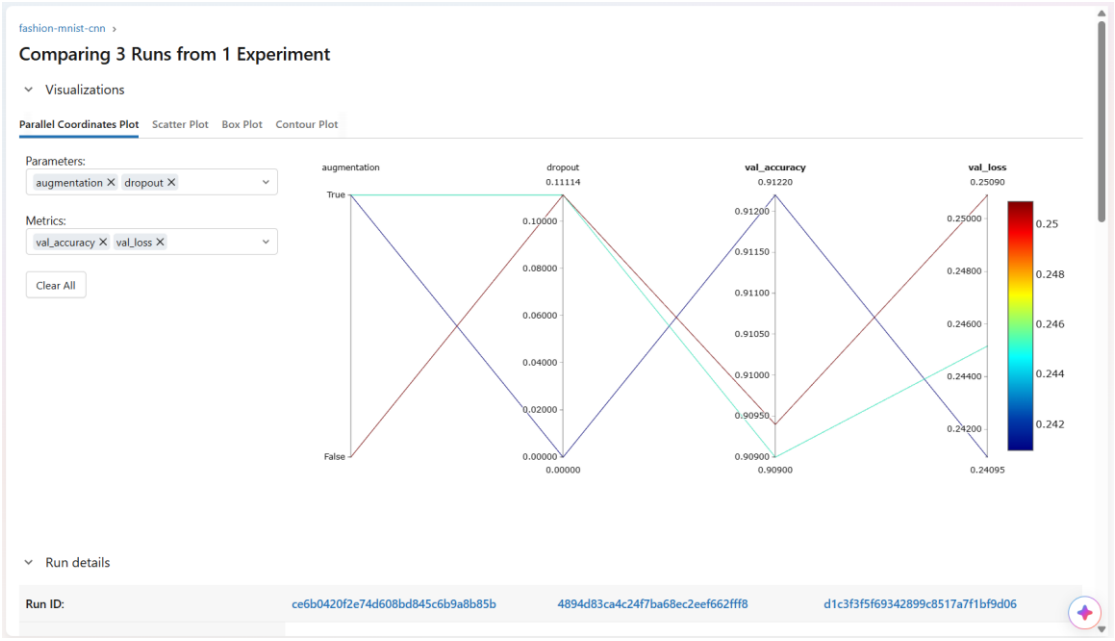
Tabel 3.3 Hasil ablation study

Konfigurasi		**Akurasi validasi**	**Validation loss**
Full model	:	90,90%	0,245
Tanpa augmentation	:	90,90%	0,251
Tanpa dropout	:	91,20%	0,241

Berdasarkan Tabel 3.3, konfigurasi tanpa *dropout* memperoleh akurasi validasi tertinggi sebesar 91,20%, dengan *validation loss* sebesar 0,241. Nilai tersebut lebih baik dibandingkan *full model* yang memperoleh akurasi validasi sebesar 90,90% dan *validation loss* sebesar 0,245. Sementara itu, konfigurasi tanpa *augmentation* memperoleh akurasi validasi sebesar 90,90%, sama dengan *full model*, tetapi memiliki *validation loss* lebih tinggi, yaitu 0,251.

Hasil tersebut menunjukkan bahwa pada eksperimen ini, penghilangan *dropout* menghasilkan peningkatan akurasi validasi sebesar 0,30 poin persentase dibandingkan *full model*. Sebaliknya, penghilangan *augmentation* tidak mengubah akurasi validasi, tetapi menghasilkan *validation loss* yang lebih tinggi. Meskipun demikian, karena setiap konfigurasi hanya diuji menggunakan satu *random seed*, hasil ini belum cukup untuk menyimpulkan bahwa penghilangan komponen tersebut selalu meningkatkan performa model.

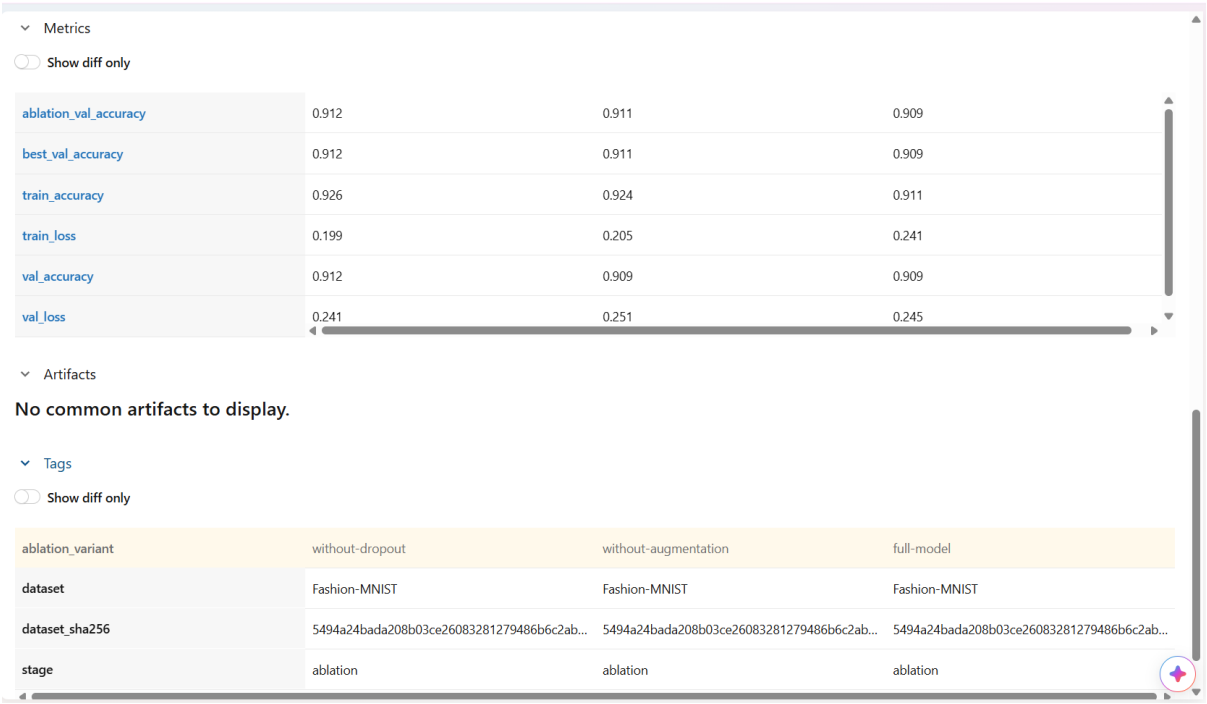
Perbandingan parameter dan metrik validasi ketiga konfigurasi pada MLflow ditunjukkan pada Gambar 3.8.



Gambar 3.8. Perbandingan Parameter dan Metrik Validasi pada Eksperimen Ablation Study Menggunakan MLflow.

Gambar 3.8 memperlihatkan perbandingan parameter *augmentation* dan *dropout* serta metrik *validation accuracy* dan *validation loss* pada ketiga konfigurasi. Visualisasi ini membantu menunjukkan perbedaan performa model berdasarkan komponen yang digunakan.

Ringkasan metrik dan identitas konfigurasi eksperimen yang dicatat pada MLflow ditunjukkan pada Gambar 3.9.



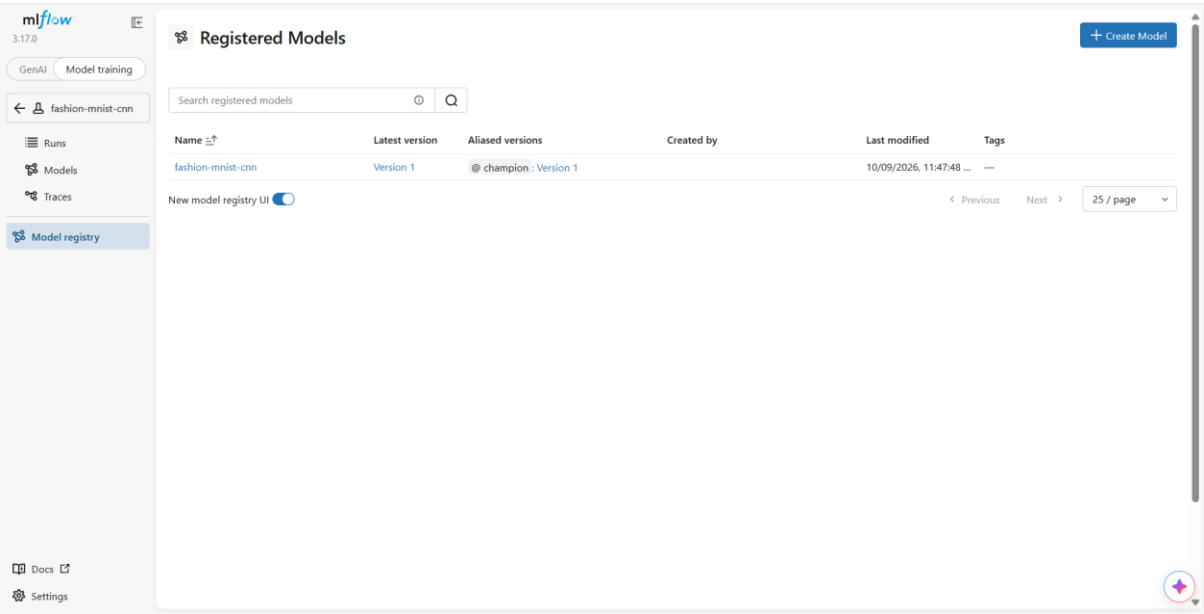
Gambar 3.9 Ringkasan Metrik dan Konfigurasi Ablation Study pada MLflow

Berdasarkan hasil eksperimen, konfigurasi *ablation-without-dropout* memperoleh akurasi validasi tertinggi sebesar 91,20% dengan *validation loss* sebesar 0,241. Hasil tersebut lebih baik dibandingkan konfigurasi *ablation-full-model* yang memperoleh akurasi validasi sebesar 90,90% dengan *validation loss* sebesar 0,245. Sementara itu, konfigurasi *ablation-without-augmentation* memperoleh akurasi validasi sebesar 90,90% dengan *validation loss* sebesar 0,251.

Dibandingkan dengan *full model*, penghilangan *dropout* menghasilkan peningkatan akurasi validasi sebesar 0,30 poin persentase dan penurunan *validation loss* sebesar 0,004. Sebaliknya, penghilangan *augmentation* tidak mengubah akurasi validasi, tetapi meningkatkan *validation loss* sebesar 0,006. Dengan demikian, konfigurasi tanpa *dropout* memberikan performa validasi terbaik di antara ketiga konfigurasi yang diuji. Namun, karena setiap konfigurasi hanya diuji menggunakan satu *random seed*, hasil ini belum cukup untuk menyimpulkan bahwa penghilangan *dropout* selalu meningkatkan performa model. Pengujian menggunakan beberapa *random seed* diperlukan untuk mengetahui konsistensi perbedaan performa tersebut.

3.5 Hasil Registrasi dan Pengujian Model

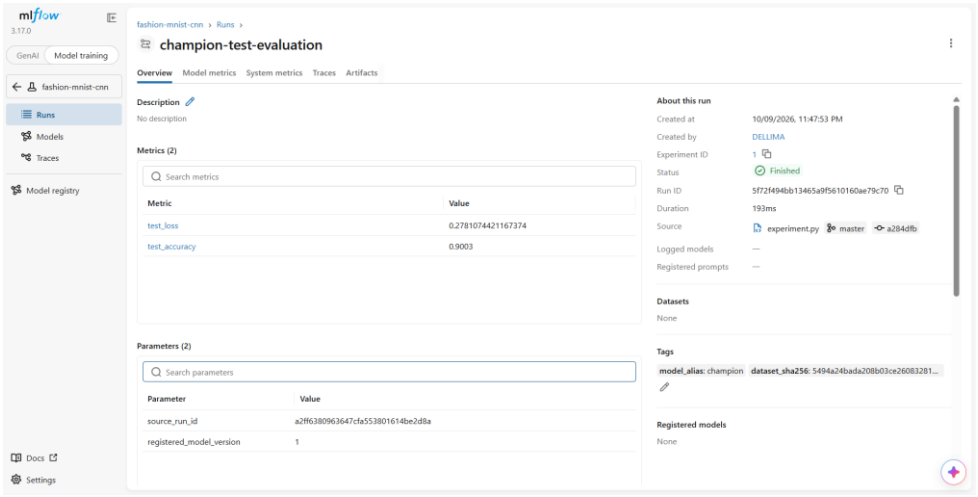
Setelah proses *hyperparameter tuning*, evaluasi menggunakan tiga *random seed*, dan *ablation study* selesai dilakukan, tahap berikutnya adalah registrasi model menggunakan MLflow Model Registry. Model CNN terbaik didaftarkan dengan nama fashion-mnist-cnn dan tercatat sebagai versi 1. Registrasi ini bertujuan untuk menyimpan model yang telah dilatih agar dapat dikelola, ditelusuri, dan dipanggil kembali melalui alias yang ditetapkan.



Gambar 3.10. Hasil registrasi model CNN pada MLflow Model Registry.

Berdasarkan Gambar 3.10, model fashion-mnist-cnn berhasil didaftarkan pada MLflow Model Registry sebagai versi 1 dengan alias champion. Alias tersebut digunakan sebagai penanda versi model yang dipilih sehingga model dapat dipanggil tanpa harus menentukan nomor

versinya secara langsung. Selanjutnya, model yang terdaftar dievaluasi menggunakan data pengujian untuk mengetahui performanya pada data yang tidak digunakan dalam pelatihan.



Gambar 3.11 Hasil pencatatan evaluasi model champion pada MLflow.

Berdasarkan Gambar 3.11, proses evaluasi model tercatat pada run champion-test-evaluation dengan status Finished. Hasil evaluasi menunjukkan nilai *test accuracy* sebesar 0,9003 atau 90,03% dan *test loss* sebesar 0,2781. Parameter registered_model_version mencatat versi model yang dievaluasi, sedangkan tag model_alias menunjukkan alias champion yang digunakan. Hasil tersebut menunjukkan bahwa model yang diregistrasikan memperoleh akurasi sebesar 90,03% pada data pengujian.

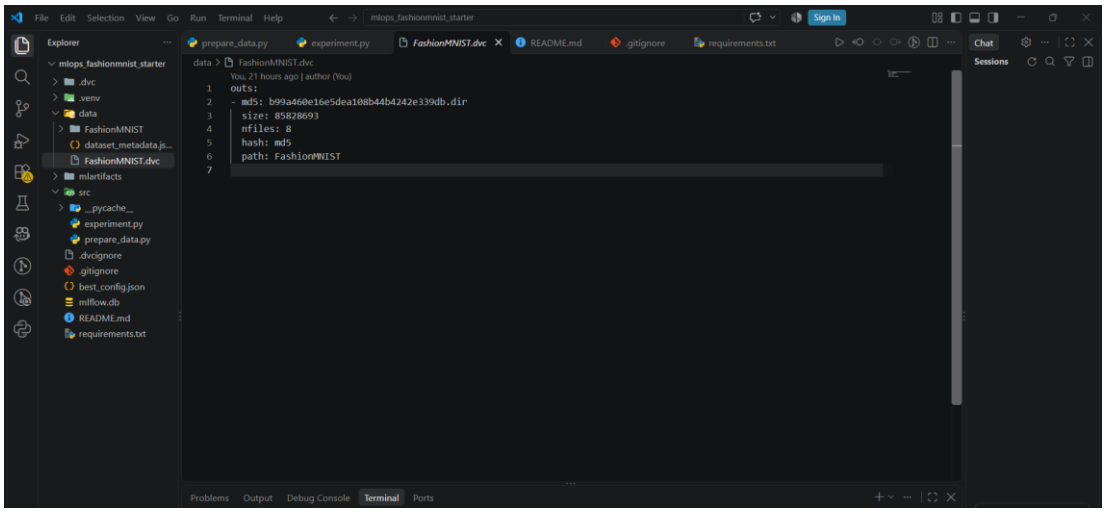
Selain mencatat metrik evaluasi, MLflow digunakan untuk menyimpan informasi yang mendukung keterlacakan eksperimen, seperti parameter versi model dan tag identitas dataset. Dengan demikian, proses registrasi dan evaluasi model dapat ditelusuri kembali melalui MLflow. Pengujian inferensi menggunakan citra individual dapat dilakukan sebagai pengujian lanjutan untuk memperlihatkan keluaran prediksi model secara langsung.

3.6 Pengelolaan Versi dan Integritas Dataset Menggunakan DVC

Pengelolaan versi dan integritas dataset merupakan salah satu aspek penting dalam alur kerja *Machine Learning Operations* (MLOps). Pengelolaan ini bertujuan untuk memastikan bahwa dataset yang digunakan dalam eksperimen dapat diidentifikasi, ditelusuri, dan diperiksa status perubahannya. Pada proyek ini, Data Version Control (DVC) digunakan untuk mengelola versi dataset Fashion-MNIST, sedangkan nilai hash SHA-256 digunakan sebagai identitas untuk membantu memeriksa konsistensi metadata dataset. Selain itu, MLflow digunakan untuk mencatat identitas dataset melalui tag pada run eksperimen sehingga informasi dataset dapat ditelusuri bersama hasil eksperimen.

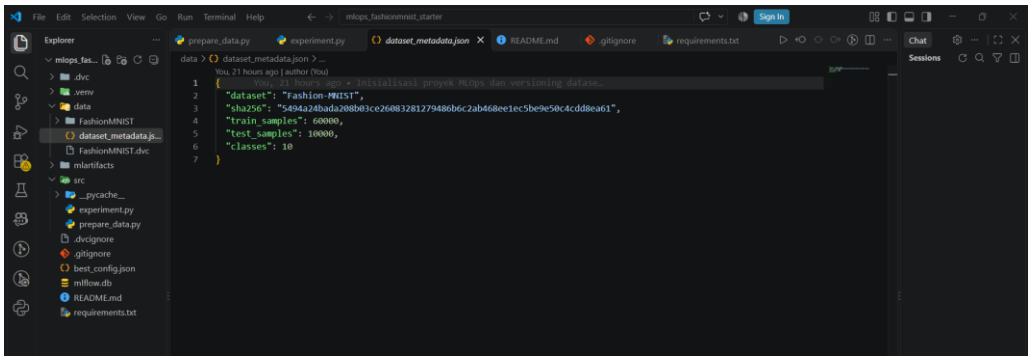
Proses pengelolaan versi dataset dilakukan dengan menambahkan direktori dataset Fashion-MNIST ke DVC menggunakan perintah dvc add data/FashionMNIST. Perintah tersebut menghasilkan file data/FashionMNIST.dvc yang berisi informasi mengenai data yang dikelola. File ini mencatat hash MD5 direktori dataset, ukuran data, jumlah berkas, dan lokasi dataset. Berdasarkan file metadata tersebut, direktori dataset memiliki hash MD5

b99a460e16e5dea108b244b4242e339db.dir, ukuran data sebesar 85.828.693 byte, dan jumlah berkas sebanyak delapan file.



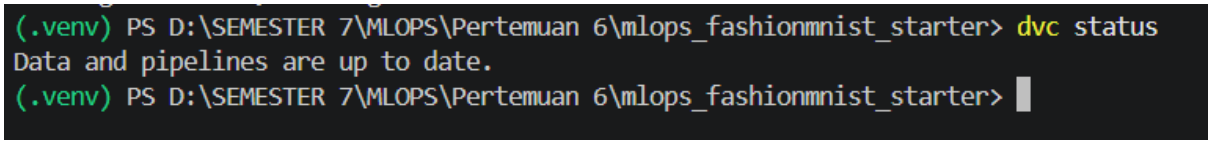
Gambar 3.12. Pencatatan hash dan identitas dataset pada MLflow.

Berdasarkan Gambar 3.12, identitas dataset Fashion-MNIST dicatat pada MLflow melalui tiga tag, yaitu dataset, dataset_sha256, dan dataset_dvc_md5. Tag dataset menunjukkan nama dataset yang digunakan, sedangkan dataset_sha256 menyimpan nilai SHA-256 dari metadata dataset dan dataset_dvc_md5 menyimpan hash MD5 yang diambil dari file metadata DVC. Pencatatan ini bertujuan untuk menghubungkan identitas dataset dengan run eksperimen sehingga informasi dataset yang berkaitan dengan suatu eksperimen dapat ditelusuri melalui MLflow.



Gambar 3.13. Metadata dataset Fashion-MNIST yang memuat nilai SHA-256 dan jumlah data.

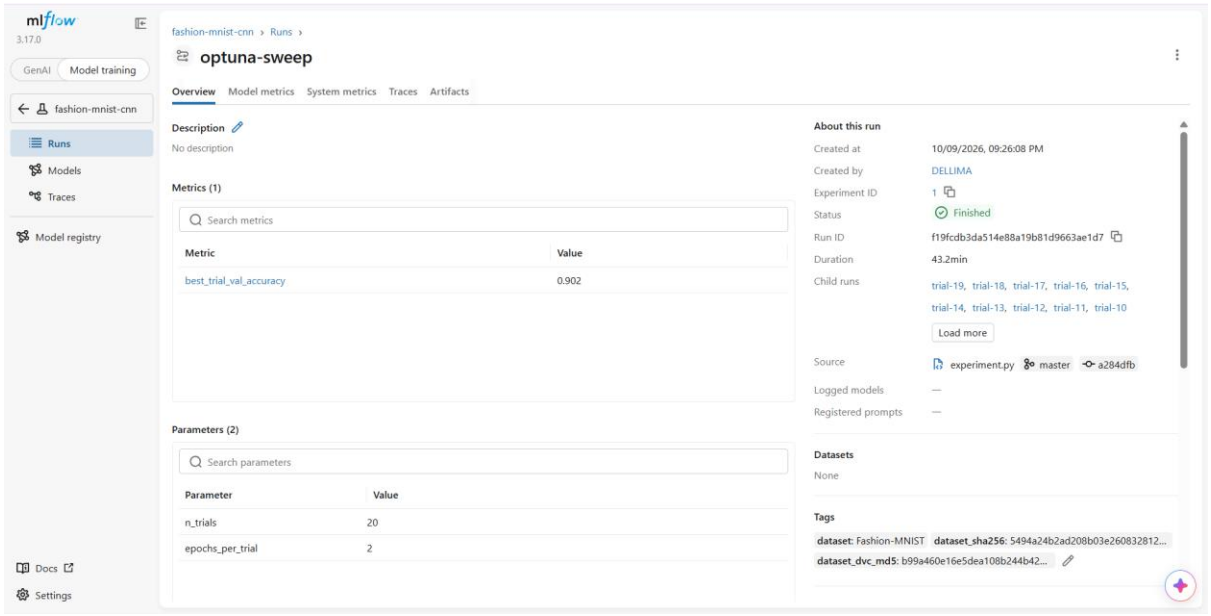
Selain file metadata DVC, proyek ini menggunakan file data/dataset_metadata.json untuk menyimpan informasi identitas dan karakteristik dataset. Berdasarkan Gambar 3.13, metadata tersebut memuat nama dataset Fashion-MNIST, nilai hash SHA-256, jumlah data pelatihan sebanyak 60.000 sampel, jumlah data pengujian sebanyak 10.000 sampel, serta jumlah kelas sebanyak 10. Nilai SHA-256 digunakan sebagai identitas untuk membantu memeriksa konsistensi metadata, sedangkan informasi jumlah sampel dan kelas mendokumentasikan karakteristik dataset yang digunakan dalam eksperimen.



Gambar 3.14. Hasil pemeriksaan status dataset menggunakan DVC.

Setelah dataset dikelola menggunakan DVC, pemeriksaan dilakukan dengan menjalankan perintah dvc status. Berdasarkan Gambar 3.14, terminal menampilkan pesan Data and pipelines are up to date. Hasil tersebut menunjukkan bahwa DVC tidak mendeteksi perubahan yang belum tercatat pada data atau pipeline yang dipantau ketika pemeriksaan dilakukan. Pemeriksaan ini menjadi salah satu langkah untuk memastikan bahwa status data yang dikelola DVC sesuai dengan catatan versi yang tersedia. Namun, hasil tersebut tidak secara otomatis membuktikan bahwa seluruh eksperimen historis menggunakan isi dataset yang identik.

Pencatatan hash dataset juga diterapkan pada run eksperimen di MLflow. Salah satu contohnya ditunjukkan pada Gambar 3.15, yaitu run optuna-sweep yang digunakan dalam proses *hyperparameter tuning*. Pada run tersebut, tag dataset, dataset_sha256, dan dataset_dvc_md5 tercatat bersama hasil eksperimen. Run optuna-sweep juga mencatat nilai akurasi validasi terbaik sebesar 0,902 atau 90,20% dari 20 *trial* yang dilakukan. Hal ini menunjukkan bahwa informasi identitas dataset dapat ditelusuri bersama hasil eksperimen *hyperparameter tuning*.



Gambar 3.15. Pencatatan hash dataset pada run *hyperparameter tuning* di MLflow.

Pencatatan hash melalui MLflow dilakukan dengan fungsi log_dataset_tags() pada kode eksperimen. Fungsi tersebut mencatat nama dataset, hash SHA-256 dari metadata dataset, dan hash MD5 yang diambil dari file DVC. Mekanisme ini diterapkan pada fungsi eksperimen yang memanggil pencatatan tag tersebut. Untuk memastikan bahwa persyaratan pencatatan hash pada setiap run telah terpenuhi, keberadaan tag dataset_sha256 dan dataset_dvc_md5 perlu diperiksa pada seluruh run yang relevan, termasuk run evaluasi tiga *random seed*, *ablation study*, serta evaluasi model.

Secara keseluruhan, penggunaan DVC, metadata SHA-256, dan MLflow mendukung pengelolaan versi serta keterlacakan dataset dalam proyek MLOps Fashion-MNIST. DVC digunakan untuk mengelola versi dan memeriksa status dataset, file metadata digunakan untuk mendokumentasikan identitas serta karakteristik dataset, sedangkan MLflow digunakan untuk menghubungkan identitas dataset dengan catatan eksperimen. Dengan demikian, pengelolaan dataset menjadi bagian dari dokumentasi eksperimen yang mendukung keterlacakan dan upaya reproduksibilitas model.

3.7 Ringkasan Hasil Eksperimen

Berdasarkan rangkaian eksperimen yang telah dilakukan, penerapan model Convolutional Neural Network (CNN) pada dataset Fashion-MNIST dievaluasi melalui beberapa tahapan, yaitu pelatihan model baseline, *hyperparameter tuning* menggunakan Optuna, evaluasi dengan tiga *random seed*, *ablation study*, registrasi model, serta pengelolaan versi dan integritas dataset. Setiap tahapan memberikan informasi mengenai performa model dan mendukung dokumentasi proses eksperimen dalam alur kerja MLOps. Pada tahap baseline, model CNN memperoleh akurasi validasi sebesar 87,14%. Selanjutnya, proses *hyperparameter tuning* menggunakan 20 *trial* Optuna menghasilkan konfigurasi terbaik pada *trial* ke-12 dengan akurasi validasi sebesar 90,20%. Hasil tersebut menunjukkan adanya peningkatan akurasi validasi sebesar 3,06 poin persentase dibandingkan hasil baseline pada eksperimen yang dilakukan.

Evaluasi menggunakan tiga *random seed*, yaitu 42, 123, dan 2026, menghasilkan akurasi validasi masing-masing sebesar 91,06%, 92,00%, dan 91,96%. Rata-rata akurasi validasi yang diperoleh sebesar 91,67% dengan standar deviasi sampel sekitar 0,53 poin persentase. Hasil ini memberikan gambaran mengenai variasi performa model ketika proses pelatihan dilakukan menggunakan seed yang berbeda. Pada tahap *ablation study*, model penuh (*full model*) memperoleh akurasi validasi sebesar 90,90%. Eksperimen tanpa *data augmentation* juga memperoleh akurasi sebesar 90,90%, sedangkan eksperimen tanpa *dropout* menghasilkan akurasi sebesar 91,20%. Di antara ketiga varian yang diuji, eksperimen tanpa *dropout* memperoleh akurasi validasi tertinggi. Namun, karena pengujian dilakukan dengan satu *random seed*, hasil tersebut belum cukup untuk menyimpulkan bahwa penghilangan *dropout* selalu meningkatkan performa model.

Setelah rangkaian eksperimen tersebut, model fashion-mnist-cnn berhasil didaftarkan pada MLflow Model Registry sebagai versi 1 dengan alias champion. Evaluasi pada data pengujian menghasilkan *test accuracy* sebesar 90,03% dan *test loss* sekitar 0,2781. Hasil ini menunjukkan performa model pada data pengujian yang digunakan dalam evaluasi. Selain mengevaluasi performa model, proyek ini menerapkan pengelolaan versi dataset menggunakan DVC dan pencatatan identitas dataset melalui hash SHA-256 serta MD5. Informasi tersebut dicatat dalam metadata dataset dan tag MLflow untuk mendukung identifikasi dataset serta keterlacakan eksperimen. Pemeriksaan dvc status juga menunjukkan bahwa data dan pipeline berada dalam kondisi *up to date* ketika pemeriksaan dilakukan. Secara keseluruhan, rangkaian eksperimen mencakup evaluasi performa model, analisis variasi hasil pelatihan, pengujian pada data pengujian, registrasi model, serta pengelolaan versi dataset. Penggunaan Optuna membantu proses pencarian hiperparameter, MLflow mendukung pencatatan hasil eksperimen dan pengelolaan model, sedangkan DVC digunakan untuk mengelola versi dataset. Dengan demikian, proyek ini menerapkan beberapa komponen utama MLOps untuk mendukung keterlacakan dan pengelolaan eksperimen machine learning.

BAB IV

PENUTUP

4.1 Kesimpulan

Berdasarkan eksperimen *Model Experimentation & Tracking in MLOps* yang telah dilakukan pada dataset Fashion-MNIST, dapat disimpulkan bahwa MLflow berhasil digunakan untuk mencatat dan menelusuri eksperimen pelatihan model Convolutional Neural Network (CNN). Pencatatan meliputi parameter, metrik evaluasi, tag identitas dataset, serta artefak hasil eksperimen. Selain itu, DVC digunakan untuk mengelola versi dataset, sedangkan hash SHA-256 dan MD5 dicatat untuk mendukung identifikasi dataset dan keterlacakan eksperimen.

Proses *hyperparameter tuning* menggunakan Optuna dengan 20 *trial* menghasilkan konfigurasi terbaik pada *trial* ke-12 dengan akurasi validasi sebesar 90,20%. Konfigurasi tersebut menggunakan *learning rate* sekitar 0,002676, *batch size* 64, *dropout* sekitar 0,1111, dan 32 *channels*. Evaluasi menggunakan tiga *random seed*, yaitu 42, 123, dan 2026, menghasilkan rata-rata akurasi validasi sebesar 91,67% dengan standar deviasi sampel sekitar 0,0053 atau 0,53 poin persentase. Hasil *ablation study* menunjukkan bahwa konfigurasi tanpa *dropout* memperoleh akurasi validasi tertinggi sebesar 91,20%, sedangkan konfigurasi tanpa *data augmentation* dan model lengkap masing-masing memperoleh akurasi sebesar 90,90%. Hasil tersebut berlaku pada konfigurasi dan pelaksanaan eksperimen yang dilakukan, sehingga belum dapat digunakan untuk menyimpulkan bahwa penghilangan *dropout* selalu meningkatkan performa model.

Model CNN selanjutnya berhasil didaftarkan pada MLflow Model Registry dengan nama fashion-mnist-cnn, versi 1, dan alias champion. Evaluasi model yang dipanggil melalui alias tersebut menghasilkan akurasi pada data pengujian (*test accuracy*) sebesar 90,03% dan nilai *test loss* sekitar 0,2781. Hasil ini menunjukkan bahwa model memperoleh akurasi sebesar 90,03% pada data pengujian yang digunakan. Secara keseluruhan, penerapan MLflow, Optuna, dan DVC membantu membuat proses eksperimen lebih terstruktur serta mendukung pencatatan hasil, pengelolaan model, dan keterlacakan dataset.

4.2 Saran

Berdasarkan hasil eksperimen yang telah dilakukan, terdapat beberapa pengembangan yang dapat dipertimbangkan pada eksperimen selanjutnya. Pertama, jumlah *trial* pada proses *hyperparameter tuning* dapat ditingkatkan untuk mengeksplorasi konfigurasi hiperparameter yang lebih beragam. Kedua, setiap variasi pada *ablation study* dapat diuji menggunakan beberapa *random seed* agar hasil perbandingan lebih representatif dan pengaruh variasi proses pelatihan dapat dianalisis dengan lebih baik.

Ketiga, evaluasi model dapat dilengkapi dengan metrik *precision*, *recall*, dan *F1-score*, serta *confusion matrix*, untuk memperoleh gambaran yang lebih menyeluruh mengenai kemampuan klasifikasi pada setiap kelas Fashion-MNIST. Keempat, pengelolaan artefak dan dataset dapat dikembangkan dengan menggunakan *remote storage* agar penyimpanan, akses, dan pemulihan data maupun artefak eksperimen menjadi lebih mudah. Pencatatan hash dataset juga perlu diverifikasi pada setiap run yang relevan untuk memperkuat keterlacakan eksperimen.

Terakhir, pengujian inferensi menggunakan citra individual dari data pengujian dapat dilakukan untuk memperlihatkan hasil prediksi model beserta label sebenarnya dan menilai kesesuaian hasil prediksi dengan kelas citra.

Repositori Kode Program

Kode program, konfigurasi eksperimen, dan berkas pendukung implementasi MLOps dapat diakses melalui repositori GitHub berikut:

Tautan repositori: Repository Github